Intitation à RStudio

Introduction

- Nous allons étudier la programmation avec R.
- Nous sommes dans un Notebook.
- $\bullet\,$ Nous pouvons écrire des fomules de mathématiques en LATEX.
- Par exemple, je peux écrire une équation comme :

$$x^2 - 12x + 14 = 0.$$

• Des formules un peu plus sophistiquées

$$\int_{-\infty}^{+\infty} e^{-x^2} dx = \sqrt{\pi}.$$

Mettre un lien hypertexte Le wikipedia du Cnam.

Les Chunks

• Pour exécuter des lignes de code en R, vous pouvez insérer ces lignes à partir du menu.

1+1

[1] 2

Probability and statistics with R

Vectors

```
x <- 5
x
## [1] 5
y <- c(7, 3, 5)
y
## [1] 7 3 5
z <- c(2, 4, 6, 8)
length(z)
## [1] 4
length(x)
## [1] 1
length(y)
## [1] 3</pre>
```

```
x + y
## [1] 12 8 10
y + z # Opération non souhaitée car pas de même longueur
## Warning in y + z: longer object length is not a multiple of shorter object
## length
## [1] 9 7 11 15
# Supposons que z soient des prix en euros. Pour les convertir en dollars, il suffit de faire
0.87*z
## [1] 1.74 3.48 5.22 6.96
     LogVec \leftarrow (x < z) \# logical vector LogVec \# 5 < 2, 5 < 4, 5 < 6, 5 < 8 [1] FALSE FALSE
    TRUE TRUE typeof(LogVec)
LogVec \leftarrow (x < z)
LogVec
## [1] FALSE FALSE TRUE TRUE
typeof(LogVec)
## [1] "logical"
typeof(x)
## [1] "double"
## [1] 2 4 6 8
z[2]
## [1] 4
typeof(z)
## [1] "double"
z<-as.integer(z)</pre>
typeof(z)
## [1] "integer"
LETTERS ## vecteur contenant les lettres de l'alphabet
## [1] "A" "B" "C" "D" "E" "F" "G" "H" "I" "J" "K" "L" "M" "N" "O" "P" "Q" "R" "S"
## [20] "T" "U" "V" "W" "X" "Y" "Z"
LETTERS[10] ## 10ème lettre
## [1] "J"
LETTERS[c(1, 2, 3, 4)] ## Les quatre premières lettres
## [1] "A" "B" "C" "D"
LETTERS[1:20] ## Les vingt premières lettres
## [1] "A" "B" "C" "D" "E" "F" "G" "H" "I" "J" "K" "L" "M" "N" "O" "P" "Q" "R" "S"
```

```
## [20] "T"
1:20 ## crée une liste (ou un vecteur) des nombres de 1 à 20
## [1] 1 2 3 4 5 6 7 8 9 10 11 12 13 14 15 16 17 18 19 20
1980:2021 ## Créez un vecteur d'années de 1980 à 2021
## [1] 1980 1981 1982 1983 1984 1985 1986 1987 1988 1989 1990 1991 1992 1993 1994
## [16] 1995 1996 1997 1998 1999 2000 2001 2002 2003 2004 2005 2006 2007 2008 2009
## [31] 2010 2011 2012 2013 2014 2015 2016 2017 2018 2019 2020 2021
seq(1980,2021,4)
                              ## Créez un vecteur des années bisextiles depuis 1980
## [1] 1980 1984 1988 1992 1996 2000 2004 2008 2012 2016 2020
## [1] 2 4 6 8
z[1] ## Garder le premier élément
## [1] 2
z[-1] ## Enlever le premier élément
## [1] 4 6 8
z[c(1,2)]
             ## Garder les deux premiers éléments
## [1] 2 4
z[-c(1,2)] ## Enlever les deux premiers éléments
## [1] 6 8
z[-(1:2)] ## Idem
## [1] 6 8
z[z>5] ## Garder les éléments supérieurs à 5
## [1] 6 8
data<-c(rep(c("Nord","Oui"),0.3*30000),</pre>
rep(c("Nord","Non"),0.1*30000),
rep(c("Sud","Oui"),0.2*30000),
rep(c("Sud","Non"),0.4*30000))
data<-matrix(data,nrow=30000,ncol=2,byrow=TRUE)</pre>
data<-as.data.frame(data)</pre>
typeof(data)
## [1] "list"
class(data)
## [1] "data.frame"
is.data.frame(data)
## [1] TRUE
class(x)
```

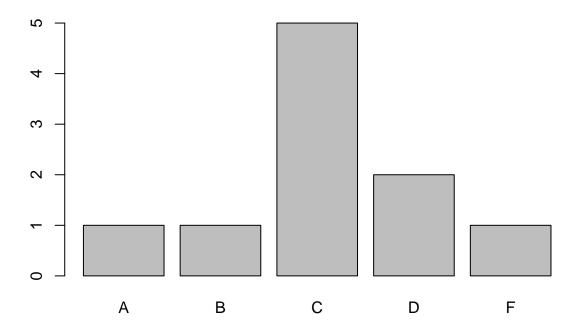
```
## [1] "numeric"
typeof(x)
## [1] "double"
names(data) <- c("Région", "Réponse")
head(data)
##
     Région Réponse
## 1
      Nord
## 2
      Nord
                Oui
## 3
      Nord
                Oui
## 4
     Nord
                Oui
## 5
      Nord
                Oui
## 6 Nord
                Oui
te < - table (data) ## Tableau d'effectifs
##
         Réponse
## Région
          Non
                  Oui
##
     Nord 3000 9000
     Sud 12000 6000
##
  ## Tableau de proportions
prop.table(te) ## Calcule le tableau en proportions à partir du tableau en effectifs
##
         Réponse
## Région Non Oui
     Nord 0.1 0.3
##
     Sud 0.4 0.2
addmargins(prop.table(te)) ## Rajoute les marges, sommes en ligne et en colonne
##
         Réponse
## Région Non Oui Sum
    Nord 0.1 0.3 0.4
     Sud 0.4 0.2 0.6
##
     Sum 0.5 0.5 1.0
addmargins(prop.table(te,1),2) ## Calcule les prop. en ligne (en conditionnant par les lignes) et rajou
##
         Réponse
## Région
                          Oui
                {\tt Non}
     Nord 0.2500000 0.7500000 1.0000000
     Sud 0.6666667 0.3333333 1.0000000
addmargins(prop.table(te,2),1) ## Calcule les prop. en colonne (conditionnelles) et rajoute les marges
##
         Réponse
## Région Non Oui
##
    Nord 0.2 0.6
##
    Sud 0.8 0.4
    Sum 1.0 1.0
##
Grades <- c("A", "D", "C", "D", "C", "C", "C", "C", "F", "B") # Crée la variable
Grades # Affiche la variable
## [1] "A" "D" "C" "D" "C" "C" "C" "C" "F" "B"
```

```
table(Grades) # Crée une table de fréquence
## Grades
## A B C D F
## 1 1 5 2 1
xtabs(~Grades) # Idem avec la fonction xtabs
## Grades
## A B C D F
## 1 1 5 2 1
table(Grades)/length(Grades) # Crée la table en prop.
## Grades
   Α
        В
            С
                D
## 0.1 0.1 0.5 0.2 0.1
prop.table(table(Grades)) # Idem
## Grades
   A B
            С
                D
## 0.1 0.1 0.5 0.2 0.1
prop.table(xtabs(~Grades)) # Idem
## Grades
   A B
## 0.1 0.1 0.5 0.2 0.1
Utiliser des données qui se trouvent dans un Package
library(MASS) # Active le Package MASS
# data(package="MASS") # Montre tous les fichiers de données du Package MASS
head(quine) # Montre les 6 premières ligne de du fichier quine
    Eth Sex Age Lrn Days
##
         M FO SL
## 1
     Α
         M FO SL
## 2
                      11
      Α
## 3
         M FO SL
                      14
      Α
## 4
                       5
      Α
         M FO AL
## 5
      Α
          M FO AL
                       5
## 6
          M FO
                      13
table(quine$Age)
##
## F0 F1 F2 F3
## 27 46 40 33
xtabs(~Age,data=quine) # Effectifs par Age
## Age
## F0 F1 F2 F3
## 27 46 40 33
names(quine) # Donne le nom des variables
```

```
## [1] "Eth" "Sex" "Age" "Lrn" "Days"
xtabs(~Age+Sex,data=quine) # On croise la variable Age et Sex
##
      Sex
## Age F M
    FO 10 17
##
##
    F1 32 14
##
    F2 19 21
##
    F3 19 14
addmargins(xtabs(~Age+Sex,data=quine))
##
       Sex
## Age
         F
            M Sum
   F0 10 17 27
   F1 32 14 46
##
##
    F2 19 21 40
   F3 19 14 33
##
##
    Sum 80 66 146
#table(quine$Age) accessing Age using dollar prefixing
```

Utiliser les pipes

```
library(magrittr)
library(MASS) # Charger une librairie pour les pipes
xtabs(~Age+Sex,data=quine) %>%
addmargins()
##
       Sex
## Age
         F
             M Sum
        10 17 27
    F0
       32 14 46
##
    F1
        19 21
    F2
##
                40
##
    F3
        19 14 33
    Sum 80 66 146
xtabs(~Grades,data=quine)%>%
barplot()
```

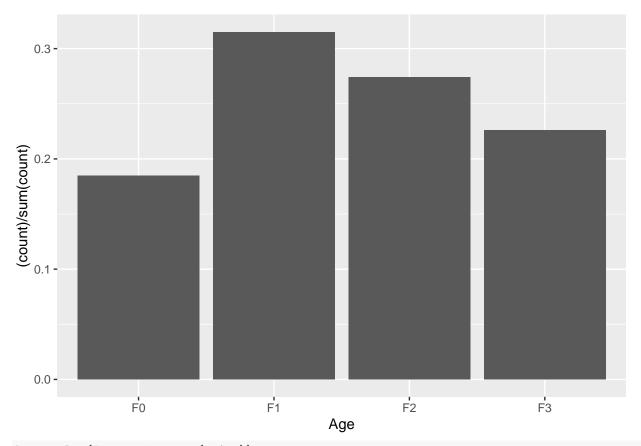


Des graphiques plus sophistiqués

```
library(ggplot2) # On charge cette librairie de dataviz
library(ggthemes) # Librairie de thèmes supplémentaires
is.data.frame(quine)

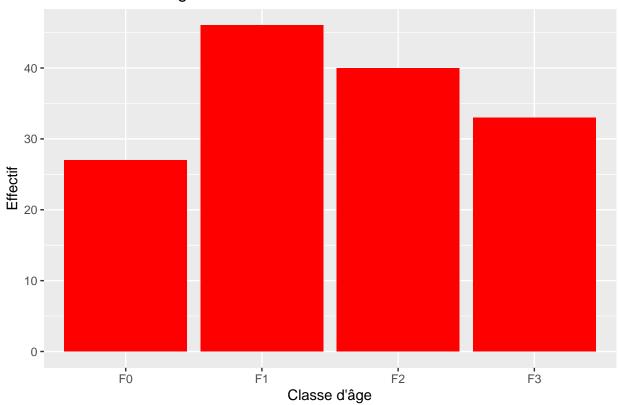
## [1] TRUE

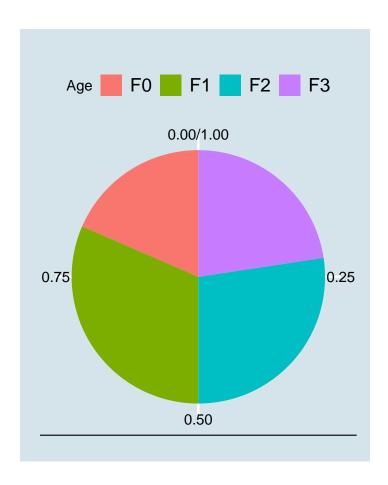
ggplot(data=quine, aes(x=Age))+
geom_bar(aes(y = (..count..)/sum(..count..)))
```



bp<-ggplot(data=quine, aes(x=Age))+
geom_bar(aes(y = (..count..)),fill = "red")+ggtitle("Distribution des âges") +ylab("Effectif")+xlab("Cl
bp</pre>

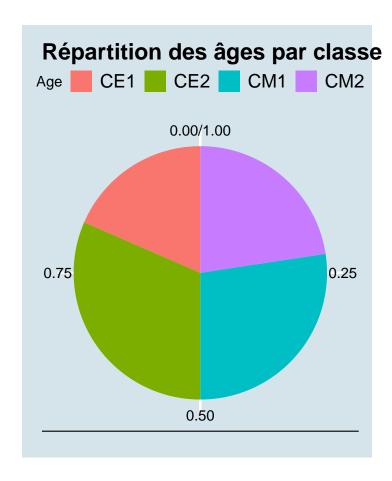
Distribution des âges





Recode variables with dplyr

```
library(dplyr)
##
## Attaching package: 'dplyr'
## The following object is masked from 'package:MASS':
##
##
       select
## The following objects are masked from 'package:stats':
##
##
       filter, lag
## The following objects are masked from 'package:base':
##
       intersect, setdiff, setequal, union
quine%>%mutate(Age=recode(Age, "F0"="CE1", "F1"="CE2", "F2"="CM1", "F3"="CM2"))->df
ggplot(df,aes(x= "", fill=Age)) +geom_bar(aes(y = (..count..)/sum(..count..)))+ggtitle("Répartition des
  coord_polar("y", start=0)+labs(x=NULL, y=NULL)
```



Statistiques descriptives

Eth	Sex	Age	Lrn	Days
A:69	F:80	CE1:27	AL:83	Min.: 0.00
N:77	M:66	CE2:46	SL:63	1st Qu.: 5.00
NA	NA	CM1:40	NA	Median $:11.00$
NA	NA	CM2:33	NA	Mean : 16.46

Eth	Sex	Age	Lrn	Days
NA	NA	NA	NA	3rd Qu.:22.75
NA	NA	NA	NA	Max. :81.00

summary_table(df)

	df (N = 146)
Eth	
A	69 (47)
N	77 (53)
Sex	
F	80 (55)
M	66 (45)
Age	
CE1	27 (18)
CE2	46 (32)
CM1	40 (27)
CM2	33 (23)
Lrn	
AL	83 (57)
SL	63 (43)
Days	
minimum	0
median (IQR)	11.00 (5.00, 22.75)
mean (sd)	16.46 ± 16.25
maximum	81

library(dummies)

dummies-1.5.6 provided by Decision Patterns

```
dummy(quine$Eth)%>%
data.frame()->dfEth
```

Warning in model.matrix.default(~x - 1, model.frame(~x - 1), contrasts = FALSE):
non-list contrasts argument ignored

```
dummy(quine$Sex)%>%
data.frame()->dfSex
```

Warning in model.matrix.default($\sim x - 1$, model.frame($\sim x - 1$), contrasts = FALSE): ## non-list contrasts argument ignored

```
dummy(quine$Age)%>%
data.frame()->dfAge
```

Warning in model.matrix.default(~x - 1, model.frame(~x - 1), contrasts = FALSE):
non-list contrasts argument ignored

```
dummy(quine$Lrn)%>%
data.frame()->dfLrn
```

Warning in model.matrix.default(~x - 1, model.frame(~x - 1), contrasts = FALSE):
non-list contrasts argument ignored

```
cbind(dfEth,dfSex,dfAge,dfLrn,quine$Days) ->df
names(df)<-c("Eth A","Eth N","Female","Male","F0","F1","F2","F3","AL","SL","Days")</pre>
```

```
knitr::opts_chunk$set(echo = FALSE)
stargazer(df,type="latex")
```

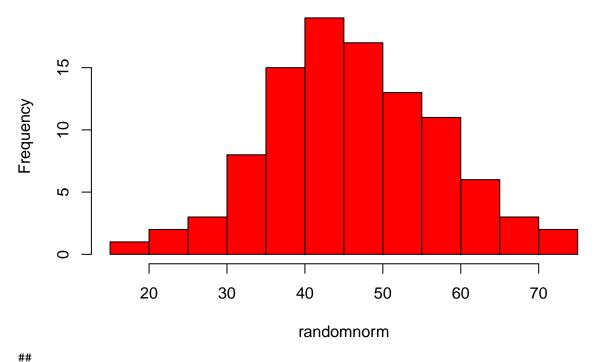
% Table created by stargazer v.5.2.2 by Marek Hlavac, Harvard University. E-mail: hlavac at fas.harvard.edu % Date and time: Thu, Apr 08, 2021 - 09:12:35

Table 2:

Statistic	N	Mean	St. Dev.	Min	Pctl(25)	Pctl(75)	Max
Eth A	146	0.473	0.501	0	0	1	1
Eth N	146	0.527	0.501	0	0	1	1
Female	146	0.548	0.499	0	0	1	1
Male	146	0.452	0.499	0	0	1	1
F0	146	0.185	0.390	0	0	0	1
F1	146	0.315	0.466	0	0	1	1
F2	146	0.274	0.448	0	0	1	1
F3	146	0.226	0.420	0	0	0	1
AL	146	0.568	0.497	0	0	1	1
SL	146	0.432	0.497	0	0	1	1
Days	146	16.459	16.253	0	5	22.8	81

Stem and leaf plot

Histogram of randomnorm



##
The decimal point is 1 digit(s) to the right of the |
##
1 | 7

```
## 2 | 156

## 3 | 000122233366777778889999

## 4 | 0001111122222233444556666777888999

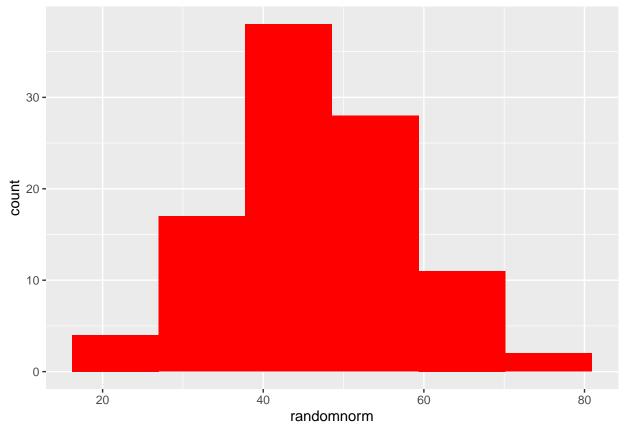
## 5 | 00000011222333455666777899

## 6 | 001133466

## 7 | 011

## [1] 17.28997

## [1] 71.248
```



Statistiques de base

```
## [1] 46.08487
## [1] 10.95379
## [1] 119.9855
## [1] 45.74108
##
     Min. 1st Qu. Median Mean 3rd Qu.
                                           Max.
    17.29
                   45.74 46.08 53.30
          39.07
                                          71.25
##
##
     randomnorm
         :17.29
  Min.
  1st Qu.:39.07
## Median:45.74
         :46.08
## Mean
## 3rd Qu.:53.30
```

Charger des données sur un lien

```
##
     age fat sex
## 1
     23 9.5
      23 27.9
## 2
                F
## 3
      27 7.8
                М
## 4
      27 17.8
## 5
      39 31.4
## 6
      41 25.9
                F
## 7
      45 27.4
                Μ
## 8
      49 25.2
## 9
      50 31.1
                F
## 10 53 34.7
                F
## 11 53 42.0
                F
## 12 54 29.1
## 13 56 32.5
## 14 57 30.3
                F
## 15 58 33.0
## 16 58 33.8
                F
## 17 60 41.1
## 18 61 34.5
```